Riassunti di Tecnologie Internet

Simone Montali monta.li

14 gennaio 2020

1 Internet

1.1 HTTP

Il World Wide Web è uno spazio di informazioni basato su internet, dove documenti e risorse sono identificati da indirizzi. Una pagina web è un documento HTML linkato ad altre pagine/risorse. Gli URI (*Uniform Resource Identifiers*) sono utilizzati in HTTP come mezzo identificativo delle risorse.

schema: [//[user:password@]host[:port]][/]path[?query][#fragment]

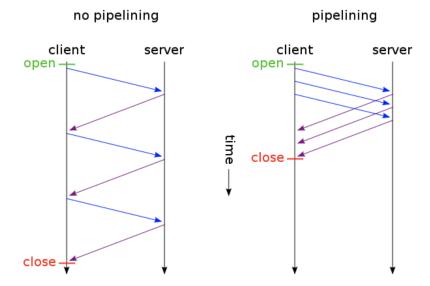
HyperTezt Transfer Protocol è un protocollo a livello applicativo, che adotta un modello client/server: uno user agent che inizia la connessione HTTP ed invia richieste, e un origin server che accetta le richieste e possiede le risorse. È inoltre utile definire altri tre termini:

- Local cache: memoria locale (server o client)
- Proxy: applicazione intermediaria avente funzionalità server e client
- Gateway: applicazione intermediaria che lavora per conto del server, senza renderlo noto ai client

1.1.1 Caratteristiche di HTTP

- HTTP utilizza TCP: il client inizia una connessione TCP (crea la socket) sul server, che accetta e comincia a scambiare messaggi, poi viene chiusa.
- HTTP è stateless: il server non mantiene informazioni riguardanti richieste passate

Distinguiamo tra HTTP non-persistent, dove abbiamo un invio di risorsa alla volta, e persistent HTTP, dove più risorse vengono inviate attraverso una singola connessione TCP. Consideriamo il cosiddetto **Round Trip Time** (RTT): nella prima sono richiesti 2 RTT per risorsa (apertura connessione, invio risorsa), mentre la seconda lascia la connessione aperta, e quindi riduce il numero di RTT richieste. Inoltre, la seconda permette il **pipelining**, ossia l'invio di più richieste alla volta allo scopo di ridurre i tempi, senza attendere le risposte.



Un messaggio HTTP è formato da request/status line, header, body. Una request line è composta da metodo target versioneHTTP. Una status line è versioneHTTP statusCode reasonPhrase. Gli headers sono in formato MIME e specificano i metadati della richiesta come data, versione MIME, encoding, connessione, proxy/gateway, content-type, content-length, encoding, linguaggio, scadenza, data di modifica... Termina sempre con un carriage return (r).

1.1.2 Metodi HTTP

Prima di elencare i metodi, denotiamo due caratteristiche:

- Idempotenza: significa che il metodo, chiamato più volte, restituirà sempre lo stesso risultato.
- Safety: significa che il metodo non modifica le risorse.

Procediamo elencando i metodi:

- GET: safe ed idempotente. Utilizzato per richiedere una risorsa, ottenuta nella risposta.
- **POST**: non safe, non idempotente. Utilizzato per creare/aggiornare una risorsa. Chiamato ripetutamente, creerà più volte la risorsa.
- PUT: idempotente ma non safe. Utilizzato per creare/aggiornare una risorsa.
- **DELETE**: *idempotente ma non safe*. Elimina la risorsa specificata.
- HEAD: safe ed idempotente. Come una GET ma restituisce solo l'header del messaggio.

Prima di procedere, distinguiamo le differenze tra POST e PUT: nella creazione di risorse, POST non specifica l'ID, mentre PUT si. Nell'update, POST permette di inviare la risorsa parzialmente (solo la parte da updatare), mentre PUT richiede la risorsa completa.

1.1.3 Header delle richieste HTTP

L'header contiene varie informazioni:

- User-Agent: descrive il client che ha originato la richiesta
- Referer: URL della pagina che ha generato la richiesta
- Host: dominio e porta a cui viene eseguita la richiesta
- From: indirizzo email del requester
- Range: range della richiesta (utilizzato per riprendere i download)
- Accept, Accept-Charset, Accept-Encoding, Accept-Language: si spiega da solo; il client specifica cosa può accettare, il server decide il suo preferito
- If-Modified-Since, If-Unmodified-Since: permette di creare GET condizionali, ad esempio se ho una risorsa in cache e voglio verificare che sia aggiornata
- Authorization, Proxy Authorization

1.1.4 Messaggi di risposta HTTP

La status line contiene un codice di stato:

- 1xx Informational: temporaneo mentre la richiesta viene eseguita
- 2xx Successo: richiesta eseguita
- 3xx Redirection: il server ha ricevuto la richiesta ma sono necessarie altre azioni del client
- 4xx Client error: la richiesta è sbagliata
- 5xx Server error: il server non è riuscito ad eseguire la richiesta

Nell'header troviamo:

- Server: stringa che descrive il server
- WWW-Authenticate: contiene una challenge per il client; in caso di 401 unauthorized, il client utilizzerà la challenge per generare un codice di autorizzazione.
- Accept-Ranges: specifica il tipo di ranges accettabili (bytes/nulla)

1.1.5 Cookies

Molti siti utilizzano i cookies. Essi sono composti da 4 componenti: header line della prima risposta HTTP, header line nella prossima richiesta HTTP, file sull'host, DB sul backend del sito.

1.1.6 Proxy

Il proxy è un'applicazione intermediaria che ha funzionalità server e client. Un **transparent proxy** non modifica la richiesta o risposta (es. HTTP tunneling), un **non-transparent proxy** modifica la richiesta/risposta per fornire servizi aggiuntivi. Possiamo utilizzare un proxy server per soddisfare richieste senza coinvolgere il server originale: se la richiesta è nella cache, restituisce la risposta, altrimenti la inoltra.

1.2 Apache

Apache nasce dal desiderio di migliorare httpd, il software server più utilizzato agli inizi di internet; è attualmente utilizzato per mantenere più del 50% di internet. La sua architettura è formata da:

- Moduli: compilati staticamente nel server o contenuti in una directory /modules o /libexec, caricata dinamicamente a runtime
- Apache httpd: implementa il ciclo di processamento delle richieste, composto da più fasi
- Multi-Processing Module: strato intermedio tra Apache e il sistema operativo, che gestisce i thread/processi
- Apache Portable Runtime: librerie che forniscono uno strato tra il sistema operativo e le utilities, in modo da poter essere portable

Apache 2.0 utilizza un processo per connessione, I/O blocking. I Multi-Processing Modules bindano le porte della macchina e accettano richieste.

1.2.1 Configurazione

La configurazione è eseguita tramite semplici file di testo, posizionati in varie directory e spesso divisi in più file e caricati tramite *Include directives*. Una configurazione minimale richiede 5 directives:

- 1. User: setta lo user ID con cui il server risponderà a richieste (utilizzare i permessi minimi)
- 2. Group: setta il gruppo con cui il server risponderà a richieste (necessario avviare il server come root inizialmente)
- 3. ServerName: setta lo schema delle richieste, hostname e porta. È in pratica l'URI.
- 4. DocumentRoot: setta la directory di base delle richieste, a meno di specifiche di Alias.
- 5. Listen: setta la/le porta/e su cui accettare richieste

In più, abbiamo:

- ErrorLog: indica dove salvare il log degli errori
- CustomLog: indica un file dove salvare un log delle richieste, ed un filtro per decidere quali richieste loggare.
- Include: permette di includere altri file di configurazione
- LoadModule: linka una libreria/file oggetto e lo aggiunge ai moduli attivi.
- IfModule: permette di verificare se un modulo è installato ed eseguire directives di conseguenza.

Tramite virtual hosting possiamo hostare più siti sullo stesso server, distinguendoli in due possibili modi: tramite IP o nome. Con la seconda, non c'è necessità di IP multipli. Possiamo anche applicare delle configurazioni locali in determinate directory, e tramite le Options directives attivare/disattivare features, come: ExecCGI, FollowSymLinks, SymLinksIfOwnerMatch, Includes, IncludesNOEXEC, Indexes. Inoltre, è possibile utilizzare i file .htaccess per definire cambiamenti alla configurazione in directories: inseriamo il file in una cartella e tutte le modifiche alla configurazione verranno eseguite lì e nelle subfolders. Tramite

la AllowOverride della configurazione, decidiamo quali directives possono essere overridate dagli htaccess. Per migliorare le performance di Apache, il sistemosta può modificare le opzioni di Apache: è però sconsigliabile usare spazio di swap (RAM virtuale). Infine, con la directive ErrorDocument, specifichiamo cosa fare quando si incorre in un errore HTTP specifico, con 4 possibilità: messaggio hardcoded di errore (default), messaggio custom, redirect interno, redirect esterno.

1.2.2 Avvio di Apache

Su sistemi Unix httpd viene eseguito come daemon continuamente; se la directive Listen è sulla porta 80, è necessario avviare Apache come root perché è una porta speciale (poi verranno lanciati child processes). Lanciamo Apache con l'apachect1 control script, che setta le variabili ENV necessarie e poi avvia httpd. Se l'avvio è succesful, il server viene detacchato dalla console (scusate). Si può usare apachect1 per terminare Apache, o killare il daemon.

1.3 HTML

Il web è basato su tre risorse: gli URI, i protocolli, e HTML. HTML è un linguaggio universale che permette la creazione di documenti con formattazioni, contenuti, link, design. Nasce dalla mente di Tim Berners-Lee e conta attualmente 5 versioni major, la cui ultima è 5.2. Per promuovere l'interoperabilità, ogni documento HTML deve specificare il suo character set, formato da repertorio e code positions. Inoltre, va specificato l'encoding nell'header delle richieste HTTP. Distinguiamo tra 3 parti: una linea di versione HTML, un header, un corpo. Nell'header possiamo trovare varie tipologie di tag: TITLE, BASE, LINK, SCRIPT, STYLE, META. Nel corpo, possiamo trovare DIV (block-level) e SPAN (inline). Un heading descrive l'argomento della sezione che introduce (H1..H6 in base all'importanza). Abbiamo anche alcuni tag per il testo: BR va a capo, P delimita un paragrafo, PRE delimita un testo preformattato, EM, STRONG, CITE, DFN, CODE, SAMP, KBD, VAR, ABBR, ACRONYM, BLOCKQUOTE, Q, SUB, SUP. Possiamo creare liste: UL (Unordered List), OL(Ordered List), DL(Definition List). Possiamo creare tabelle: TABLE, TR, TD. Possiamo spaziarle utilizzando rowspan e colspan, captionarle con CAPTION. Possiamo creare links con il tag A, avente attributi href e target(_blank, _self, _parent, _top). Dando ID agli elementi HTML possiamo cercarli tramite gli anchor link (#riferimento). Con l'elemento IMG embeddiamo immagini definite nell'attributo src. Con OBJECT definiamo oggetti come risorse, applets, plugin. Con i frame possiamo generare views multiple; un frame ha head, frameset e body, con attributi rows e cols. Possiamo anche creare forms, che contengono contenuto, markup, controlli, labels e li inviano ad un'action (tramite GET o POST). In HTML5 sono stati inoltre definiti nuovi tag, semantici (header, footer, article, section), di controllo (numeri, date, orari, calendari, range), grafici (svg., canvas), multimediali (audio, video). Non sono più supportati i frames, sostituiti dagli iframes.

1.4 CSS

HTML non è nato per contenere tag di definizione di stile, ma piuttosto per mostrare dati. Quando cominciarono a venire aggiunti tag di stile ad HTML 3.2, come font, color, si capì che non poteva funzionare. Il World Wide Web Consortium (W3C) creò quindi Cascading File Sheets (CSS). In HTML4, tutta la formattazione poté quindi essere definita separatamente dall'HTML, dando la possibilità di modificare l'intero sito con un solo sito web.

1.4.1 Sintassi

La sintassi consiste in un selettore, seguito da varie dichiarazioni:

```
h1 { color:blue; font-size:12px; }
```

Il selector punta all'elemento HTML desiderato, mentre nel blocco di dichiarazione inseriamo una o più dichiarazioni separate da ;. I selettori possono indicare una tipologia HTML, come p, una classe, come .rowDiv, un ID, come #title. Possiamo includere CSS in tre modi:

- Style sheet esterno: <LINK rel="stylesheet" type="text/css" href="file.css">
- Style sheet interno: <STYLE> body{}</STYLE>
- Inline: <H1 style="color:blue;">

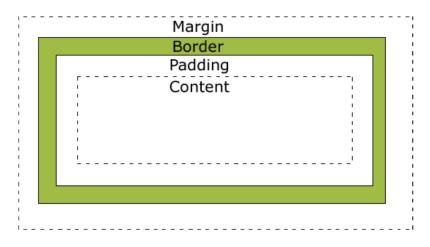
1.4.2 Attributi notevoli

Alcuni attributi importanti:

- Background: background-color, background-image, background-repeat, background-attachment, background-position
- Text: color, text-align, text-decoration, text-transform, text-indent
- Fonts: permette di definire una font family (generica o specifica) con sistema fallback: le prova in ordine finché non trova la funzionante; è quindi meglio partire con specifica e terminare con generica. Oltre a font-family, abbiamo font-style (italic, oblique), font-size, font-weight
- Links: possiamo applicare ogni CSS property, ed in più abbiamo 4 selector speciali (A:link, A:visited, A:hover, A:active)
- Lists: possiamo settare i marker delle liste, o addirittura immagini come item markers con list-style-image
- Tables: possiamo specificare i borders tramite la proprietà border, e anche width/height. Inoltre, anche text-align e vertical-align sono disponibili.

1.4.3 Box model

In CSS sfruttiamo il *pattern* del box model: essenzialmente è ciò che wrappa un contenuto, che ci permette di aggiungere padding, bordi, margini.



$1.5 \quad XML$

Sembrerà un linguaggio inutile e passato (perché lo è), ma nella sezione SOA ci sono ben due lezioni che si basano su sto schifo. *Ocio*. XML sta per **eXtensible Markup Language** e serve per trasportare informazioni, non per presentarli (come HTML). I tag non sono definiti in uno standard, ma dall'utente. Possiamo, per esempio sfruttare XML per separare i dati variabili da HTML.

Quando usare XML? XML semplifica il salvataggio e la condivisione di dati, essendo un formato standard basato su testo. Semplifica i cambiamenti di piattagorma, essendo testo semplice. Tra i linguaggi scritti in XML, citiamo SVG, WSDL, RSS.

1.5.1 Struttura

Il documento XML inizia con il prologo, che definisce la versione XML. Comincia poi l'albero, che ha una root e delle leaves. I figli sullo stesso livello sono detti siblings (fratelli). Tutti i figli possono avere un contenuto e degli attributi. In XML è illegale omettere il tag di chiusura (tranne ovviamente nel prologo). I tag XML sono case sensitive. Gli attributi devono essere sempre tra virgolette. I commenti sono come in HTML: <!-- Commentino -->. XML non tronca gli spazi bianchi come HTML, e salva le nuove linee come LF. Bisogna stare attenti ad alcuni caratteri, come <, che vanno escapati con sequenze specifiche: >, &, &apos, ". Gli elementi XML devono seguire alcune regole di nomenclatura:

- Case sensitivity
- Inizio con lettera o underscore
- Non si può iniziare con "XML"
- Possono contenere lettere, numeri, trattini, underscore, punti
- Non possono contenere spazi
- Le lettere accentate non sono un problema (ma occhio ai software)

Gli attributi solitamente forniscono informazioni che non sono parte dei dati, ad esempio, se avessimo un contenuto file, l'attributo potrebbe essere il filetype. Alcuni problemi degli attributi:

- Non possono contenere valori multipli
- Non possono contenere alberi
- Non sono facilmente espansibili

Per evitare conflitti di nomi, possiamo utilizzare dei prefissi di namespace con l'attributo xmlns:

Dopo aver definito un namespace, tutti i contenuti con quel prefisso verranno collegati al namespace. Definire un namespace di default è utile: ci evita di utilizzare prefissi in tutti i children. Possiamo utilizzare anche caratteri internazionali: è però importante specificare l'encoding nel prolog.

1.5.2 Validità e document types

Un documento XML corretto è detto ben formato. Un documento XML valido deve essere compatibile ad una document type definition. Ne abbiamo due diverse: DTD (Document Type Definition) e XML Schema (basata su XML). Usiamo questi document type per vari scopi: decidere standard, verificare dati dall'esterno, verificare dati nostri. XML non lo richiede per forza, ma in ambienti di produzione ci vuole. Lo scopo di un DTD è definire la struttura, con una lista di elementi validi. Possiamo anche usarlo per definire caratteri speciali e stringhe di caratteri. L'XML Schema è un'alternativa basata su XML a DTD.

1.6 **JSON**

Finalmente. JSON è il cugino che ce l'ha fatta di XML. Sta per JavaScript Object Notation, ed è come XML una sintassi per salvare e scambiare dati, più leggera e semplice di XML. Dal momento che JSON è proprio il modo di definire oggetti in JavaScript, non necessita di parser. Similarità con XML: self-describing, gerarchico, portable, fetchabile con una XMLHttpRequest. Differenze con XML: niente tag di chiusura, più breve, più veloce, presenza di arrays. La sintassi di JSON è derivata da JS: i dati sono accoppiati nome/valore, separati da virgole, oggetti delimitati da {}, arrays delimitati da []. Un valore JSON può essere un numero, stringa, boolean, array, oggetto, null.

1.7 Search Engines

L'information retrieval è parte della computer science che studia il recupero di informazioni da una collezione di documenti, soddisfando le necessità dell'utente, solitamente definite in linguaggio naturale. La web search è molto simile, con alcune differenze: links tra web pages, collezionare documenti è molto più difficile, il numero di utenti è grande, lo spam è un problema. La struttura di un web search engine è composta da un downloader, un crawler, un indexer... Abbiamo eterogeneità multiple: utenti, linguaggi, document types, queries (informational, navigational, transactional, connectivity). Un crawler feeda continuamente l'indexer con informazioni nuove o aggiornate. Distinguiamo inoltre tra surface web, indexato, e deep web (da non confondere con darkweb) ossia la parte di internet non indexata, composta da pagine dinamiche, contenuti privati, script, formati particolari.

1.7.1 Web Graph

Possiamo vedere le pagine, linkate tra loro, come un grafico di pagine collegate tra in-links e out-links. La distribuzione dei links non è randomica ma segue una power law: il numero di pagine con k in-links è proporzionale a $k^{-2.1}$. Alcuni studi hanno mostrato che il web graph ha bowtie shape. Un crawler consiste in una queue di URI da visitare, un metodo per ottenere i dati, un parser che estragga i link, una connessione all'indexer. Il crawler dev'essere highly scalable: abbiamo 60mld di pagine sul web. Dobbiamo inoltre tenere conto di altri problemi: spam, duplicati, spider traps, distribuzione, latenza, banda, profondità, desideri dell'owner. In quanto owner possiamo escludere alcune risorse dall'accesso dei robots, tramite il file robots.txt. Per l'indexing, sfruttiamo la link analysis: i link sono raccomandazioni, gli anchor texts descrizioni del documento.

1.7.2 PageRank

PageRank è l'algoritmo di Larry Page (il signor Google) sviluppato a Stanford. È un algoritmo di link analysis che produce un ranking non dipendente dalle queries. È eseguito periodicamente dall'indexer. L'algoritmo si basa sulla probabilità che un utente random clicki su un link che porti alla pagina da un'altra, calcolata ricorsivamente sulla probabilità della pagina attuale e via andare... PageRank è usato

ancora oggi (in parte), soprattutto in formato topic-sensitive: una pagina su un topic specifico può non essere utile globalmente ma essere importante per il topic stesso.

1.7.3 HITS

HITS è un altro algoritmo. Cominciamo col distinguere due tipi di pagine web: authorities (fonti autoritarie sull'argomento), hubs (puntatori all'authority). C'è una relazione di reinforcement: hub di qualità puntano ad authorities di qualità. Seguiamo due fasi:

- 1. **Sampling phase**: le parole della query vanno a costruire un root set di pagine, che viene espanso a un base set, aggiungendo tutte le pagine linkate dal root set
- 2. Weight-propagation phase: ogni pagina riceve un authority-weight a_p e un hub-weight h_p pari a 1. A questo punto, a_p è la somma degli hub weights che puntano alla pagina, mentre h_p è la somma degli authority weights delle pagine linkate da p. Poi, applichiamo una normalizzazione finché i weights non convergono.

A volte HITS tende a generalizzare o a deviare dal topic, soprattutto quando gli hubs coprono più topic; una soluzione potrebbe essere comparare le parole della query con quelle che circondano il link, o frammentare un grande hub in hublets minori, ed ignorare quelli unrelated.

1.7.4 HITS vs PageRank

PageRank può essere precomputed, mentre HITS deve essere computato a query time. Abbiamo poi scelte diverse riguardanti il modello formale.

2 JavaScript

2.1 Basics

JavaScript è il linguaggio di programmazione che permette di programmare il comportamento delle pagine web. Seguendo il pattern MVC, abbiamo che il model è gestito da XML/JSON, la view da HTML+CSS, il controller da JavaScript. JavaScript non è Java e non è un linguaggio di scripting. ECMAScript è la standardizzazione ufficiale del linguaggio. Il core di JS definisce un'API minimale, ma è l'environment ad avere le responsabilità maggiori: il browser, Rhino o Node. Possiamo embeddare JS in HTML tramite: inline (tag <script>), esterno (sempre tag <script> con src), in un event handler come l'onclick, in un URL che utilizza il protocollo javascript:. Una filosofia detta unobstrusive JavaScript sottolinea che contenuto (HTML) e comportamento (JS) devono essere il più separati possibile. JS non ha metodi di print definiti, ma usiamo window.alert(), document.write(), innerHTML, console.log(). Gli statement sono separati da ;, e composti da valori, operatori, espressioni, keywords, commenti. Definiamo tra valori fissi (literals) e variabili (variables). Utilizziamo la keyword var per definire variabili, che in JS sono untyped. Essendo untyped abbiamo possibilità di confusione; JS interpreta le operazioni da sinistra a destra.

Abbiamo i soliti operatori; la concatenazione di stringhe è fatta con +. Esiste l'operatore condizionale ? : . I commenti sono fatti con // e /* */. Gli identifiers possono iniziare con lettere, underscore o dollaro e contenere lettere, numeri, underscores, dollari. Gli identifiers sono case sensitive. Le funzioni sono definite dalla keyword function seguita da nome e argomenti. Le variabili possono anche contenere oggetti,

definiti con la forma classica di JS. Inoltre, gli oggetti possono contenere funzioni (questo è importante) come se fossero semplici attributi. Possiamo creare oggetti in tre modi: con l'object literal (come JSON), con la keyword new Object () e poi settando attributi, o con una funzione costruttrice. Gli oggetti creati con i primi due metodi ereditano da un prototipo detto Object.prototype, che è in cima alla scala gerarchica. JS ha costruttori per gli oggetti nativi, come Object, String, Number, Boolean, Array, RegExp, Function e Date, ma è meglio utilizzare i literals, come {}, "", 0, false, [], /()/, function();. Gli oggetti sono indirizzati per reference, non valore, quindi la copia non è fattibile con =. Possiamo aggiungere attributi ad un oggetto semplicemente assegnandoli, ed eliminarli con la keyword delete. Tramite la proprietà prototype, possiamo modificare prototipi già definiti.

```
function Person(first, last, age, eyecolor) {
    this.firstName = first;
    this.lastName = last;
    this.age = age;
    this.eyeColor = eyecolor;
}
Person.prototype.nationality = "English";
Person.prototype.fullName = function() {
    return this.firstName + " " + this.lastName;
};
```

Possiamo loopare tra tutte le proprietà di un oggetto usando for..in. La sintassi with (object) utilizza object come prefisso di tutti gli statement enclosati. Con ECMAScript6 sono state introdotte le classi OOP, con eredità. Gli arrays sono oggetti speciali con indici numerici e non testuali, che hanno dei metodi built-in comodi come length, sort(), pop(), push(). La sort lavora però su stringhe, quindi ad esempio 25 è più grande di 100. Possiamo però fornire come argomento una compare function.

2.2 Client-side JS

L'oggetto window è l'entry point principale di tutte le feature di JS client-side. JavaScript è più puntato sulle web applications che sui web documents: i secondi funzionano con JS disattivato, le prime no. Quando un HTML parser incontra uno script, lo esegue di default. Solo gli script sincroni possono usare document.write() per inserire testo nell'input stream. Il tag script può avere attributi defer e async: il primo lo esegue a fine caricamento, il secondo lo esegue al più presto ma senza bloccare il parsing. Il core di JS non contiene meccanismi di threading, quindi due event handlers non gireranno mai allo stesso tempo; l'esecuzione single-threaded significa che i browser devono smettere di rispondere agli input quando gli script vengono eseguiti. Se c'è molta computazione, sarebbe meglio lasciar caricare il documento prima. Questa la timeline degli eventi:

- 1. Il browser crea un oggetto document e comincia a parsare la web page, aggiungendo gli elementi e i text nodes. document.readyState è ora "loading"
- 2. Quando l'HTML parser incontra degli elementi <script> senza async o defer, li aggiunge al documento e li esegue.
- 3. Quando l'HTML parser incontra degli script async comincia a scaricare lo script e continua a parsare. Lo script verrà eseguito appena scaricato.
- 4. Quando il documento è parsato, document.readyState è "interactive"
- 5. Ogni script con l'attributo defer viene eseguito nell'ordine di lettura. Questi hanno accesso alla document tree e non devono usare document.write().
- 6. Il browser lancia un evento DOMContentLoaded sull'oggetto document. Questo segna la transizione dalla fase sincrona di esecuzione alla fase asincrona event-driven.

7. Il documento è parsed, ma potrebbero ancora mancare risorse come le immagini. Quando è tutto pronto, document.readyState passa a "complete"

JS non fornisce alcun metodo per scrivere o eliminare file sul computer, ma può ottenere un FileSystem privato.

2.2.1 Same Origin Policy

La same origin policy indica che uno script può leggere solo le proprietà di finestre e documenti che hanno la stessa origine (protocollo, host, porta) del documento che contiene lo script. La policy è applicata alle richieste HTTP fatte con l'oggetto XMLHttpRequest, che permette al JS client-side di fare richieste HTTP al server da dove ha caricato il documento, ma non ad altri server. Per richieste cross-origin bisogna attivare Cross-Origin Resource Sharing.

2.2.2 L'oggetto window

L'oggetto window è l'oggetto globale per il client-side JS, le cui proprietà sono collegate a timers, location/navigation, history, browser informations, dialogs, document elements, comunicazione cross-window.

Timers I timers vengono settati con setTimeout che esegue una funzione dopo un numero definito di ms, e setInterval, che fa la stessa cosa ciclicamente ad intervalli.

Location e navigation La proprietà location dell'oggetto window si riferisce ad un oggetto location, che rappresenta l'URL corrente e i metodi per far caricare alla window un nuovo documento. La proprietà href dell'oggetto location è una stringa contenente l'URL, altre proprietà sono protocol, host, hostname, port. pathname, search, hash. L'hash ritorna l'anchor link, mentre search le query delimitate da ?. Il metodo assign della location carica un nuovo URL, replace lo fa rimuovendo la pagina corrente dall'history, reload aggiorna.

History La proprietà history della window contiene la cronologia. Ha proprietà length, metodi back() e forward(), go(n) che va avanti o indietro di n passi

Navigator La proprietà navigator contiene informazioni sul browser. L'utilizzo di queste informazioni è sconsigliato: è meglio utilizzare il feature testing. Tra le proprietà citiamo appName, appVersion, userAgent, platform. Abbiamo poi alcune proprietà non-standard: onLine, geolocation, javaEnabled(), cookieEnabled.

Screen La proprietà screen fornisce informazioni sulle dimensioni e colori del display: width, height, availWidth, availHeight (escludono menubar ecc.), colorDepth.

Dialogs L'oggetto window fornisce tre metodi per generare dialogs: alert(), confirm(), prompt().

Elementi HTML Ogni elemento del documento HTML che hanno un id diventano proprietà di window, contenenti l'oggetto HTMLElement. È però raccomandato utilizzare document.getElementById().

Multiple windows La comunicazione tra windows è possibile solo tra finestre same-origin. Il metodo open() apre una nuova finestra e ritorna l'oggetto relativo, prendendo 4 argomenti: URL, nome, attributi size/feature, boolean che indica se creare un nuovo record nell'history. Il metodo close() chiude la finestra indicata. Possiamo anche accedere agli oggetti window degli iframe tramite iframe.contentWindow e al document tramite iframe.contentDocument.

2.2.3 Scripting di documenti

Il DOM, Document Object Model è lo standard W3C per accedere ai documenti, separato in Core, XML, HTML. Quest'ultimo è uno standard e interfaccia di programmazione per HTML, definendo: gli elementi HTML come elementi, le proprietà, i metodi, gli eventi. Insomma: l'HTML DOM è uno standard per come ottenere, modificare, aggiungere o eliminare elementi HTML. Per ottenere un elemento HTML il modo più semplice è usare document.getElementById(), per il contenuto poi usiamo innerHTML. Possiamo, inoltre, modificare gli attributi con element.attribute, e lo stile element.style.property. Possiamo aggiungere/rimuovere elementi al documento con document.createElement(), document.removeChild(), document.appendChild(), document.replaceChild(), document.write(text), o settare event handlers con document.getElementById(id).onclick = function (). Altri modi di ottenere elementi sono getElementsByTagName e getElementsByClass, che ritornano liste (non array: sono navigabili allo stesso modo ma mancano alcuni metodi). L'HTML DOM ha una struttura ad albero, in cui gli elementi HTML sono nodi, aventi attributi nodeName, nodeValue, nodeType.

2.3 Client side - AJAX

Gli eventi HTML sono cose che accadono agli elementi HTML, a cui JS può reagire. Gli elementi HTML possono avere un attributo onclick a cui associare una funzione JS. Oltre ad onclick, abbiamo: onchange, onmouseover, onmouseout, onkeydown, onload...Gli event handler possono essere utilizzati per gestire gli input utente. L'HTML DOM permette di assegnare event handler agli elementi HTML.

onload e onunload Vengono triggerati quando l'utente entra o lascia la pagina, sono utilizzabili per controllare il browser, o gestire i cookies.

onchange Utilizzato spesso per la validazione dei field.

onmouseover e onmouseout Triggerano una funzione quando l'utente sposta il mouse sull'elemento.

onmousedown, onmouseup, onclick Si spiegano da soli: il primo è il down, poi up, infine click.

Utilizziamo il metodo element.addEventListener(event, function, useCapture) per aggiungere un event listener. Distinguiamo tra bubbling (primo trigger è il più interno) e capturing (primo trigger è il contenitore) come metodi di trigger. Utilizzando addEventListener possiamo aggiungere più event handlers a uno stesso evento.

2.3.1 AJAX

AJAX significa **Asynchronous JavaScript and XML**, ed è una tecnica per creare pagine web veloci e dinamiche. AJAX permette di aggiornare le webpages in modo asincrono, scambiando dati con il server e modificando il contenuto senza ricaricare tutta la pagina. Il punto chiave di AJAX è l'oggetto XMLHttpRequest, che permette di fare richieste HTTP. Bisogna verificare se è supportato, altrimenti usare un ActiveXObject (*Microsoft vaffanculo*). Apriamo la richiesta tramite open(method, url, async)

e la inviamo tramite send() per GET e send(string) per POST. Per evitare di farci ritornare dati cachati, aggiungiamo alla GET una query casuale. Per aggiungere headers a una POST, utilizziamo setRequestHeader(header, value). Bisogna stare attenti alla same-origin policy. Per ottenere la risposta, utilizziamo l'attributo responseText o responseXML dell'oggetto richiesta. Come il document, la request ha un attributo readyState (0..4), un relativo evento onreadystatechange e un attributo status che contiene lo status HTTP. Quando readyState è 4 e status 200, è andato tutto bene. Potremmo quindi aggiungere una callback all'onreadystatechange, verificando queste due condizioni prima.

2.3.2 jQuery

jQuery è una leggera libreria "write less, do more" che rende più semplice il JS. Abbiamo due versioni, una di produzione minified, difficilmente leggibile, e una di sviluppo. Per utilizzare jQuery lo referenziamo nell'head del documento, hostandolo sul server o caricandolo da un CDN. La sintassi di jQuery permette di selezionare elementi HTML semplicemente: \$(selettore). Per evitare di eseguire codice jQuery prima del corretto caricamento della pagina, mettiamo il codice dentro un document ready event. In jQuery, la maggior parte dei DOM events hanno un metodo jQuery corrispondente, per esempio \$("p").click(function()). jQuery permette anche di definire eventi custom, firabili con trigger(nome, datiOpzionali), e handlabili con .on("evento", function()).

2.3.3 Animazioni con jQuery

jQuery permette anche di implementare animazioni: un esempio sono i metodi hide(speed, callback) e show(speed, callback). Speed può essere "slow", "fast", o un valore di millisecondi. Callback viene invece eseguito al termine dell'animazione. Il metodo toggle() alterna tra show e hide. Abbiamo anche dei metodi di fade: fadeIn(s, c), fadeOut(s, c), fadeToggle(s, c), fadeTo(s, opacity, callback). Possiamo anche slidare elementi: slideDown(s, c), slideUp(s, c), slideToggle(s, c). Grazie al metodo animate({parametri}, s, c) possiamo creare animazioni custom modificando proprietà CSS. Di default, jQuery lavora per queue sulle animazioni: le fa una alla volta.

2.3.4 Manipolazione del DOM con jQuery

jQuery permette anche di manipolare il DOM tramite 4 metodi che settano o leggono: text(), html(), val(), attr(). Abbiamo metodi per aggiungere contenuto: append(), prepend(), after(), before(). Metodi per rimuovere contenuto: remove() (filtrabile), empty(). Possiamo modificare il css: addClass(), removeClass(), toggleClass(), css(). Questo non è tutto: ci sono anche metodi per modificare dimensioni, navigare gli elementi, funzionalità AJAX (ad esempio, richieste GET con \$.get(url, callback)).

2.3.5 Client-side storage

Le web apps possono utilizzare API del browser per salvare dati sul computer. I dati salvati possono essere visualizzati solo da pagine dello stesso sito. Abbiamo più modi di salvare roba: WebStorage API, Cookies, Filesystem API...

Web Storage L'API Web Storage fornisce due oggetti: window.localStorage (senza scadenza) e window.sessionStorage (eliminata con la chiusura della tab). Prima di utilizzarle è bene verificare la disponibilità della feature.

2.3.6 Scripted graphics

Generare grafiche complesse nel browser è molto meglio: rimuove il carico dal server per affidarlo al computer, risparmiando in banda, CPU, RAM...Inoltre è consistent con le moderne architetture applicative. In HTML5 è stato introdotto l'elemento <canvas> che ha lo scopo di ospitare grafiche generate da JS. Deve ovviamente avere un ID per essere trovato da JS. Tramite canvas.getContext() otteniamo l'oggetto context, che contiene metodi per disegnare sul canvas, come moveTo(), lineTo(), stroke(), beginPath(), arc(x, y, r, start, stop). Possiamo riempire anche con gradient: createLinearGradient(x, y, x1, y1), createRadialGradient(x, y, r, x1, y1, r1) da riempire poi con addColorStop(). Possiamo scrivere nel canvas con le proprietà: font, fillText(text, x, y), strokeText(text,x, y), fillStyle, textAlign. Possiamo inserire immagini tramite drawImage(img, x, y), opzionalmente con width e height o addirittura clippando l'immagine.

2.3.7 Frameworks importanti

Elenchiamo ora alcuni framework importanti.

AngularJS Citato come Model-View-Whatever, velocizza la programmazione, il testing, il data-binding.

Angular Ha feature che permettono di creare prodotti vari, da web a desktop a mobile.

React Creato ed utilizzato da Facebook, è molto efficiente con applicazioni ad alto traffico. È più impegnativo da imparare, ma diretto e semplice.

Ember Ottimo framework utilizzato da Chipotle, Kickstarter, LinkedIn, Netflix...

Vue Introdotto nel 2016, cerca di unire il meglio di Ember, React, Angular in un pacchetto veloce e semplice. Molto utile per single page applications.

Meteor Permette sviluppo rapido e semplice di applicazioni end-to-end performanti. Citiamo inoltre alcuni IDE: WebStorm, Atom, VSCode (spacca), Brackets.

2.4 Server side - NodeJS

Node è una piattaforma costruita sul Chrome JavaScript runtime che fornisce un'API asincrona con I/O non-blocking che lo rende leggero ed efficiente. Il programma può richiedere una risorsa e continuare con il suo lavoro, poi una callback gestisce il risultato. Il giochino è lo stesso delle richieste HTTP su jQuery, semplicemente ora accediamo a un filesystem e non ad una risorsa remota. Node è designed per data-intensive real-time(DIRT) applications. È creato per essere responsive e per avere consistenza tra browser e server, reimplementando oggetti comuni come la Timer API e la Console API, aggiungendo un core set di moduli per network e file I/O: HTTP, POSIX (filesystem), DB...

Per rendere una pagina disponibile, ad esempio, ci basterà fare:

```
var http = require('http');
http.createServer(function (req, res) { res.writeHead(200, {'Content-Type': 'image/png'}); fs.cres
}).listen(3000);
console.log('Server running at http://127.0.0.1:3000/');
```

I dati sono letti dal file tramite uno stream, ed inviati al client (.pipe)

2.4.1 Modularità

È più facile navigare nel codice se è organizzato con directory e file separati. Il sistema di moduli di Node fornisce un meccanismo potente per organizzare il codice. I moduli ci permettono di selezionare quali funzioni e variabili del file incluso sono esposte all'applicazione tramite exports. Node Package Manager (npm) è una collezione online di moduli node. I moduli possono essere singoli file o directories; se è una directory, il file principale sarà index.js, a meno che non specifichiamo diversamente nel package.json. Per utilizzare il metodo, sfruttiamo la funzione require di Node, che prende un path come argomento. Require è una delle poche operazioni I/O sincrone di Node.

2.4.2 Programmazione asincrona

Le callbacks definiscono la logica da eseguire al completamento di un'operazione. Gli event emitters firano eventi. Una callback è una funzione, passata come argomento ad una funzione asincrona, che descrive cosa fare dopo. Una caratteristica importante è che la maggior parte dei moduli di Node usano callbacks con due argomenti: err e res, il primo riempito solo in caso di errore. Gli event emitters firano gli eventi; molti componenti di Node, come i server HTTP o TCP e gli stream, sono implementati come event emitters, customizzabili con channel.emit().

2.4.3 Sequenziare logiche asincrone

Durante l'esecuzione di un programma asincrono, ci sono alcune task che possono accadere in ogni momento, mentre altre devono accadere solo prima o dopo altre. Il concetto di sequenziare gruppi di task asincrone è detto **flow control**, di cui distinguiamo due tipi: serial e parallel.

Serial Per implementare il flow control seriale, creiamo un array di tasks e lo attraversiamo una alla volta, grazie a un metodo next(err, result), che chiameremo in fondo ad ogni funzione, e che shifta l'array ogni volta.

Parallel Anche qui, aggiungiamo le funzioni a un array dinamicamente, ad esempio scorrendo un albero di file, poi le facciamo partire in parallelo.

2.4.4 Node e MySQL

Possiamo utilizzare MySQL con Node installando il modulo corretto da npm. Poi, basta creare un oggetto connection da cui possiamo chiamare il metodo connection.query(query, callback(err, rows, fields)), che contiene le rows di risposta, scorribili con un for. Questa funzione query ha anche degli eventi 'error', 'fields', 'result', triggerati ad ogni risultato. Possiamo pausare la query per eseguire operazioni prima di proseguire coi risultati, tramite connection.pause() e connection.resume(). Connection ha inoltre un evento 'close', triggerato quando la connessione si chiude, volutamente o no. Possiamo controllare se 'err' è istanziato nella callback, in modo da catchare eventuali errori.

3 Service Oriented Architectures

La Service-Oriented Architecture è lo stile architetturale prevalente nei correnti middleware per sistemi informativi distribuiti. L'obiettivo principale è permettere ad agenti debolmente coupled e software di cooperare. Un servizio è una work unit svolta da un provider, per ottenere un risultato richiesto da un consumer.

Servizio Il servizio è una procedura, metodo o oggetto con interfaccia pubblica e stabile, invocabile da un client. Può essere considerato come la caratterizzazione astratta e incapsulamento dell'interfaccia di un contenuto/risorsa specifico.

Service Interface Una service interface è definita in termini di protocollo utilizzato per interagire, formato dei dati scambiati, comportamento atteso dopo lo scambio di alcuni messaggi.

Ciclo di vita di un servizio Un servizio ha 3 fasi di vita:

- 1. Creazione: il servizio viene pubblicato in una directory o con advertisements
- 2. **Procurement**: il provider e il consumer stabiliscono un service provision contract, tramite discovery e negotiation
- 3. Enactment: il servizio è utilizzato

Ruoli La SOA è basata sull'interazione tra 3 ruoli: provider, registry, consumer.

Quality of Service La stessa service interface può corrispondere a diverse implementazioni, con provider differenti e QoS diverse. La QoS è collegata ad aspetti non funzionali, tra cui performance, disponibilità, robustezza, autorizzazioni necessarie, costi. Provider e consumer devono stabilire un Service Level Agreement (SLA), che è un agreement di QoS.

3.1 XML-based Services

Un XML-based service è un servizio implementato al web application layer, basato su un set di tecnologie XML-based. Nella maggior parte delle specifiche standard, i servizi XML-based sono detti **Web Services**. La definizione formale vuole che: "Un web service è un componente software progettato per supportare interazione macchina a macchina in rete. Ha un'interfaccia definita in un formato processabile da macchine (WSDL). Altri servizi interagiscono in una maniera decisa dalla descrizione, tramite messaggi SOAP, tipicamente convogliati tramite HTTP con serializzazione XML." Insomma: se un componente software ha un'interfaccia descritta in WSDL ed interagisce con un client scambiando messaggi SOAP, è un web service. I web services permettono alle applicazioni di cooperare attraverso il web, in modo distribuito, platform-independent, programming language independent. Quali sono le caratteristiche uniche dei web services?

- Basato su XML
- Loosely-coupled: un consumer non è strettamente legato allo specifico web service
- Coarse-grained: un pezzo di business logic
- Permette composizione al volo di nuove funzionalità, composizione, decomposizione, distribuzione su larga scala.

3 standard definiscono gli elementi critici dei web services: Simple Object Access Protocol (SOAP), protocollo per lo scambio di messaggi, Web Service Description Language (WSDL), linguaggio di descrizione di service interfaces, Universal Description, Discovery, Integration (UDDI), protocollo per l'elencazione di servizi in una directory.

Architettura WS, prima generazione Qui, gli RPC-style web services sono interface driven, tightly coupled (i parametri sono descritti nel WSDL e non in uno schema esterno XML), sincroni. Invece, i document-style sono document-driven e loosely coupled: processano input XML, eseguono operazioni sui payload, costruiscono e inviano output XML. Questi sono asincroni, con potenziale per strutture complesse.

Architettura WS, seconda generazione Qui, SOAP, WSDL e UDDI non bastano più: si cominciano a implementare soluzioni per sicurezza message-level, transazioni cross-service, messaggi affidabili, orchestration, estensioni... Etichettiamo le nuove specifiche come WS-*, come ad esempio WS-Security.

3.1.1 SOAP

SOAP fu inizialmente pensato per risolvere il gap tra le piattaforme di comunicazione RPC-based. Venne poi evoluto in un protocollo di comunicazione per web services, con un formato di messaggi standard: documenti XML capaci di hostare RPC (Remote Procedure Call) ma anche document-centric data. La specifica SOAP copre 4 aspetti:

- Formato di messaggi basato su XML per comunicazione unidirezionale e stateless
- Descrizione di come un messaggio SOAP (che è un file XML) deve essere trasportato su HTTP o SMTP
- Regole per la gestione di messaggi SOAP e la classificazione delle entità coinvolte: quali parti devono essere lette da chi, cosa fare in caso di errori
- Convenzioni per le RPC e l'invio di risposte, per gli RPC-style WS.

Ogni messaggio SOAP è costituito da un'envelope che contiene dati, diviso in due parti: header (opzionale e divisibile in blocchi) e body (obbligatorio e divisibile in blocchi). SOAP non specifica come utilizzare queste due parti, ma solitamente l'header contiene dati utili al SOAP middleware, mentre il body contiene dati per l'applicazione. Lo schema è così composto:

Il namespace soap serve per distinguere le versioni di soap, e definisce la struttura. L'attributo encodingStyle è utilizzato per definire i data types utilizzati nel documento. L'attributo può apparire su ogni elemento SOAP, e si applica ai contenuti dell'elemento e a tutti i child. L'header opzionale contiene informazioni application specific, come autenticazione, pagamenti, riguardanti il messaggio SOAP. Se è presente dev'essere il primo elemento dell'Envelope. SOAP non definisce quali informazioni devono stare nell'header, ma supporta l'uso di attributi che specifichino quali nodi devono processare un message block:

- role: URI del role che ha il permesso di processare il message block. Può essere application-defined, o uno tra: "none" (informazione propagata senza processarla), "next" (ogni nodo che riceve il messaggio può processare il blocco), "ultimateReceiver" (il blocco può essere processato solo dall'ultimo receiver)
- mustUnderstand: utilizzato per indicare se un'header entry è obbligatoria o opzionale per il destinatario
- relay: determina se un blocco dell'header è relayabile se non processato

Quindi, ogni nodo sul path del messaggio controlla il role associato ad ogni blocco: esso decide chi è responsabile per il blocco. Se il blocco non ha ruoli, il default è ultimateReceiver. Se mustUnderstand + attivo, il nodo con ruolo specificato deve processare il blocco o generare una fault. Se relay è attivo, un nodo che lo processa deve inoltrarlo (altrimenti potrebbe rimuoverlo). L'uso di relay insieme a next è utile per stabilire informazioni persistenti sul message path.

SOAP Body Il body contiene gli elementi effettivamente utili all'endpoint. Potremmo ad esempio avere una richiesta fatta così:

```
<?xml version="1.0"?>
<soap:Envelope xmlns:soap="http://www.w3.org/2001/12/soap-envelope"</pre>
 soap:encodingStyle="http://www.w3.org/2001/12/soap-encoding">
    <soap:Body>
        <m:GetPrice xmlns:m="http://www.w3schools.com/prices">
            <m:Item>Apples</m:Item>
        </m:GetPrice>
    </soap:Body>
</soap:Envelope>
E una relativa risposta:
<?xml version="1.0"?>
<soap:Envelope xmlns:soap="http://www.w3.org/2001/12/soap-envelope"</pre>
 soap:encodingStyle="http://www.w3.org/2001/12/soap-encoding">
    <soap:Body>
        <m:GetPriceResponse xmlns:m="http://www.w3schools.com/prices">
            <m:Price>
                 1.90
            </m:Price>
        </m:GetPriceResponse>
    </soap:Body>
</soap:Envelope>
```

L'elemento opzionale SOAP fault è utilizzato per indicare messaggi di errore, ed è infatti contenente errori e status. Se è presente, deve essere un child del Body e può apparire una sola volta. Contiene due elementi obbligatori: Code che specifica la categoria di errore (tra Sender, Receiver, MustUnderstand, VersionMismatch, DataEncodingUnknown), e Reason, un messaggio di errore human-readable. Inoltre, può opzionalmente avere Detail, Node, Role.

SOAP binding La specifica SOAP definisce la struttura dei messaggi, non come sono scambiati. Questo gap è colmato dai SOAP bindings, meccanismi che permettono ai messaggi SOAP di essere scambiati efficacemente. HTTP è il più usato. Una richiesta SOAP HTTP ha due header obbligatori: Content-Type e Content-Length. SOAP può utilizzare GET e POST. Il SOAP Binding utilizza gli stessi status code di HTTP. Ancora attenzione a differenze tra RPC style e document style: nel primo, il client invia una richiesta contenente il nome del metodo e i parametri, ottenendo in risposta un messaggio SOAP utilizzabile per ricreare oggetti. Nella seconda, il body contiene uno o più documenti XML, senza constraint su come devono essere strutturati: per questo l'applicazione deve occuparsi del mapping dei valori a XML.

Limitazioni di SOAP SOAP ha alcune limitazioni: prime fra tutte l'utilizzo di HTTP e XML, poco ottimizzati e poco performanti. In più, è molto generico e semplice, con mancanze in sicurezza, transazioni, accounting, e sono quindi necessarie altre specifiche, ad esempio WS-Security, WS-Coordination o WS-Transactions.

3.1.2 WSDL

Un documento WSDL (Web Services Description Language) descrive un web service, specificandone la location ed i metodi. Ogni documento WSDL ha una parte astratta (data types, messaggi, operazioni esposte) ed una parte concreta (descrive bindings e service endpoints). Quindi, la parte astratta contiene:

- <types> definisce in XML i data types utilizzati
- <message> definisce i messaggi utilizzati
- <portType> descrive un set di operazioni: one-way (input ma non output), request-response (input+output), solicit-response(invia una richiesta e attende risposta), notification (output).

Mentre la parte concreta:

-

binding> specifica il protocollo e il data format per ogni portType
- <port> specifica un indirizzo endpoint
- <service> è un set di ports

Binding Il binding definisce il formato dei messaggi e i dettagli del protocollo dei messaggi (in particolare, SOAP)per le operazioni e i messaggi di un particolare portType. Un portType può avere bindings multipli. L'attributo name deve essere unico nel documento WSDL, type indica il portType a cui il binding è riferito. L'elemento soap:binding ha due attributi: style e transport. Style può essere "rpc" o "document", transport indica il protocollo, es. HTTP. Per ogni operazione esposta da un portType bisogna definire la corrispondente azione SOAP. È anche necessario specificare l'encoding: "encoded" o "literal".

Port Un elemento port definisce un singolo service endpoint, specificante un unico binding address. Il valore di name deve essere unico nel documento WSDL; un service può avere una o più ports. Se più ports appartengono allo stesso portType, sono intese come alternative: hanno stesso comportamento ma binding differenti. Un consumer, consultando le ports del servizio, trova i portTypes che può utilizzare.

WSDL 2.0 In WSDL 2.0, abbiamo dei pattern di scambio di messaggi: In-Only (input singolo, niente faults), Robust In-Only (input singolo, possibili fault), In-Out(A come input, B output uguale a fault message in caso di errori)

3.1.3 UDDI

Universal Description, Discovery and Integration è uno standard directory services, che permette ai software agents il dynamic binding (discovery e use) di Web Services. Permette di trovare i servizi necessari tra quelli disponibili, fornendo informazioni su come chiamarli. La registrazione di servizi e la discovery sono basate su messaggi SOAP: l'UDDI registry è infatti realizzato come un web service. Distinguiamo tre operazioni principali di un directory service:

- Registration: un provider di servizi registra i nomi e indirizzi dei suoi servizi
- Removal: un provider di servizi rimuove un servizio
- Lookup: un consumer cerca informazioni su servizi disponibili

Le informazioni contenute in un UDDI registry possono essere classificate in base al loro scopo: white pages (business name, descrizione, contatti, identifiers), yellow pages (categorizzazioni industriali), green pages (informazioni tecniche). Le informazioni core usate da un UDDI registry sono definite in vari schemi XML; un UDDI business registry contiene:

- businessEntity: informazioni sul business, businessKey (identifier unico, UDID), identifierBag (altri business identifier), categoryBag (business categories)
- businessService: servizi forniti
- bindingTemplate: definisce come connettersi/comunicare, descrive un'istanza di un web service a un particolare indirizzo (URL), descrive il tipo di web service offerto riferendosi ai tModels, parametri, impostazioni
- tModel: dettagli tecnici, reference a WSDL

UDDI API UDDI fornisce API per inquiry e pubblicazione, costruite su SOAP. I record UDDI sono identificati da UUIDs da 16 byte.

3.1.4 Sicurezza dei Web Services

Grazie alla sua natura (connessioni loosely coupled) e all'accesso aperto (HTTP), un SOA aggiunge nuovi requirements di sicurezza, come autenticazione, autorizzazione, privacy, integrità.

Autenticazione L'identità utente dev'essere verificata sulla base delle credenziali presentate (di vario tipo, has/knows/is).

Autorizzazione Fornire accesso a risorse basandosi sui diritti di un utente loggato.

Confidenzialità, privacy Tenere le informazioni segrete, criptando i messaggi e offuscando le parti coinvolte.

Integrità, non repudiation Assicurarsi che un messaggio rimanga inalterato durante il transito facendo firmare digitalmente i messaggi a chi li invia.

Altri requirements di sicurezza Possiamo aver bisogno anche di mediazione di credenziali, service capabilities/constraints. Spesso i WS si affidano a Public Key Infrastructures (PKI), che sono set di ruoli, policies e procedure necessarie all'utilizzo di certificati e public-key encription.

Public-key Encription La public-key encription consiste nel criptare il messaggio con la chiave pubblica del ricevitore, che può decrittare il messaggio con la sua private key. Con la private key si può anche firmare digitalmente il messaggio, utilizzando la private per verificare la firma. I WS richiedono servizi di sicurezza al livello transport e applicativo.

Transport-level security La TLS è il protocollo più utilizzato per la comunicazione transport-level, fornendo autenticazione, confidenzialità, integrity, secure key exchange. TLS fornisce un canale di comunicazione sicuro, ma quando i dati non sono in movimento non sono sicuri.

Application-level security La signature assicura la non-repudiation dell'entità che firma, e prova che i messaggi non sono stati alterati. **WS-Security** è un set di estensioni SOAP per implementare message integrity e confidenzialità dei Web Services. WS-Security fornisce profili per 5 security tokens: username, X.509, Kerberos, SAML, REL.

SAML È un linguaggio XML-based per lo scambio di informazioni di sicurezza tra online business partners. SAML convoglia informazioni di autenticazione in forma di assertions tra soggetti. Include 3 parti: SAML assertion (autenticazione e autorizzazione), Protocol (richiesta e invio di assertions), SAML bindings and profiles (mappa assertion SAML ai framework utilizzati). Un'assertion, a grandi linee, è interpretabile come "L'assertion A, generata al tempo T dall'issuer R, assicura che il soggetto S rispetta le condizioni C". Riassumendo:

- 1. Transport security per proteggere il canale di comunicazione tra consumer e provider
- 2. Application-level security per assicurare la confidenzialità criptando digitalmente il messaggio, l'integrità con la firma digitale, autenticazione/autorizzazione con username, X.509, SAML o altri token.

3.2 Servizi RESTful

REST sta per **REpresentational State Transfer** e indica un protocollo di comunicazione stateless, client-server, chacheable. Ha in realtà due significati:

- Il significato puro vede REST come uno stile architetturale, indipendente da HTTP e dal web. Può essere utilizzato con HTTP, ma non necessariamente.
- Il significato comune indica come REST è usato normalmente: chiamate HTTP tra macchine con web server standard, per postare dati, leggere dati, eliminare dati. Insomma, REST usa HTTP per tutte le operazioni CRUD.

REST è un'alternativa leggera a meccanismi come RPC e servizi XML-based, che nonostante la semplicità ha tutte le feature necessarie. REST non è uno standard: non ha specifiche W3C. Alcune componenti REST:

- Le risorse sono l'elemento chiave di un vero design RESTful. Le risorse individuali sono identificate in richieste, utilizzando ad esempio URL. Le risorse effettive sono separate dalle rappresentazioni restituite al client. Per esempio, una risposta in JSON non significa che il server utilizzi file JSON.
- Un web di risorse, nel senso che una risorsa singola non deve essere grande e contenere troppi dettagli, ma piuttosto contenere link alle informazioni addizionali (come una pagina web)
- Nessun connection state: le interazioni sono **stateless**, ogni nuova richiesta deve avere tutte le informazioni necessarie
- Le risposte devono essere cacheable quando possibile, sfruttando gli header di cache-control HTTP
- Possibilità di utilizzare server proxy per migliorare performance e scalability
- Platform independency
- Language independency
- Standards based
- Nessuna sicurezza built-in, ma possibilità di aggiungerla sopra HTTP

Possiamo inviare richieste tramite GET e POST (qui, aggiungendo anche header per parametri), ottenendo risposte XML, CSV o JSON. Non è accettabile inviare risposte in HTML. Gli **endpoints** sono funzioni disponibili attraverso l'API; una route è il nome che utilizziamo per accedere agli endpoints, usata nell'URL, e può avere più endpoints assegnati. Ad esempio, su una route potremmo avere un endpoint GET, uno PUT, e uno DELETE. Alcune guidelines per il design REST:

- 1. Non usare URL fisici (con file extension finale)
- 2. Non ritornare overload di dati, piuttosto usare meccanismo di paging
- 3. Documentare le risposte in modo completo
- 4. Se vi sono azioni aggiuntive possibile, includere l'URL nella risposta.

4 P2P

4.1 Introduzione

Il paradigma **peer-to-peer** permette a 2 o più entità di collaborare spontaneamente in una rete di pari (peers) utilizzando informazioni appropriate e sistemi di comunicazione, senza necessità di coordinamento centrale. Un sistema P2P è un tipo particolare di sistema distribuito, ossia un HW o SW contenente più di un elemento di processazione, storage, processi concorrenti, programmi multipli. Distinguiamo tra 3 tipi di sistemi peer-to-peer:

- Sistemi peer-to-peer in cui ogni peer è posseduto da un utente, che vi interagisce per mezzo di una UI
- Reti peer-to-peer in cui peer autonomi gestiscono risorse, sensori e attuatori per fornire servizi agli utenti
- Sistemi peer-to-peer ibridi in cui alcuni peer sono posseduti da utenti, mentre altri sono autonomi

Le attività di un sistema peer-to-peer sono gestite dall'environment e dai feedback interni. Gli input dell'ambiente coinvolgono solitamente un piccolo numero di peers; quando un peer riceve un input, la sua struttura interna mappa un input ad un output. Il processo di mapping potrebbe richiedere al peer di cooperare con altri peer, scambiando messaggi per trovare e consumare risorse. Reazioni localizzate seguono input localizzati. La reazione di un peer ad input diretti o indiretti dall'ambiente è definita dalla sua struttura interna, che può essere basata su regole statiche condivise dai peer (protocolli), oppure su un piano adattivo che determina modifiche strutturali in risposta ai cambiamenti dell'environment.

4.1.1 Variabili di stato

Un sistema P2P è una rete di peer; quando un peer si aggiunge, si connette agli altri per mezzo di una strategia predeterminata. Le connessioni possono cambiare nel tempo. Un peer condivide risorse: siano essere banda, cache, cpu, storage, file, servizi, applicazioni. Alcuni peer contribuiscono in minima parte consumando molte risorse: questi sono detti free riders. Distinguiamo tra risorse replicabili e risorse consumabili: le prime possono essere spostate o copiate da un peer all'altro (file, dati...), mentre le seconde non possono essere acquisite per copia, ma solo utilizzate contrattando con gli host (memoria, CPU, applicazioni, servizi). Raggruppiamo i servizi in due categorie: servizi distribuiti (che coinvolgono più peers), e servizi locali (unità funzionali esposte da peers che permettono accesso remoto alle loro risorse locali). Ogni peer ha una lifetime L, modellabile considerando i seguenti fattori: ruolo del peer, disponibilità di risorse, imprevisti. Abbiamo alcune variabili misurabili sul peer stesso: utilizzo delle risorse, tempo di risposta, query hit ratio. Altre variabili vengono settate dal peer: dimensione della routing table e strategia di riempimento, algoritmo di routing dei messaggi, banda in upload e download. Utilizziamo $\mathbf{modelli}$ $\mathbf{stocastici}$ per studiare la distribuzione delle risorse e la loro popolarità. I nodi in un network P2P non costituiscono una popolazione vera e propria, in quanto la loro crescita non dipende dalla riproduzione dei nodi; i nodi si aggiungono o lasciano per ragioni imprevedibili.

Design issues La topologia, struttura e centralizzazione della rete, il message routing e meccanismo di location sono alcune delle problematiche cruciali per il design di una rete P2P. Recentemente, la ricerca sui sistemi P2P si è concentrata sul design di schemi di overlay robusti (che definiscono regole per il bootstrapping, la connettività, il message routing, il caching). Alcuni problemi di efficienza:

- Scalabilità
- Bootstrapping (avvio)
- Gestione della connettività
- Performance di richiesta
- Consistenza
- Stabilità
- Distribuzione del carico
- Banda asimmetrica

Problemi di sicurezza:

• Attacchi passivi: eavesdropping, analisi del traffico

- Attacchi attivi: spoofing, man in the middle, playback/replay, local data alteration, no forwarding, free riding, ddos, network poisoning
- Trust management

Nei sistemi P2P, l'information placement gioca un ruolo importante nella decisione dello schema di overlay; le informazioni sulle risorse condivise possono essere pubblicate su un server centrale, pubblicate agli altri peer, salvate localmente e non pubblicate. Introduciamo 3 modelli di overlay scheme: Hybrid Model, Decentralized Unstructured Model (DUM), Decentralized Structured Model (DSM). Inoltre, citiamo il Layered Model (LM) in cui i peer sono raggruppati in strati, ognuno dei quali ha uno schema.

Hybrid Model Nel modello ibrido, i peers si connettono a uno o più server centrali dove pubblicano informazioni riguardanti le risorse che condividono. Ogni server centrale mantiene, per ogni risorsa, la lista di possessori, in alcuni casi replicando parzialmente le liste degli altri server. Dopo la richiesta di un peer, la directory centrale fornisce la lista dei peer che matchano la richiesta, o il peer migliore in termini di banda/disponibilità. Le interazioni seguenti sono poi tra il provider e il consumer. Se il server centrale non è unico, le query potrebbero essere inoltrate ai server vicini.

Decentralized Unstructured Model Ogni peer propaga richieste ai peers connessi direttamente, sefuendo una qualche strategia, per esempio il flooding, strategia che consuma molta banda ma è efficiente in comunità limitate. Per migliorare la scalabilità si può utilizzare il caching delle ricerche recenti, insieme al probabilistic flooding (ogni peer propaga il messaggio a un numero random di vicini). In più, se un'identità unica è aggiunta al messaggio, i nodi possono eliminare duplicati dello stesso messaggio, evitando la formazione di loops. In network grandi è necessario aggiungere qualche meccanismo di Time To Live per evitare il totale flooding della rete.

Decentralized Structured Model Qui, un protocollo consistente a livello glovale si assicura che ogni nodo possa inoltrare una ricerca al peer che ha la risorsa desiderata, anche se la suddetta è rara. È per questo necessario un pattern molto più strutturato di overlay links. Il tipo più utilizzato è il Distributed Hash Table (DHT), dove ogni risorsa deve essere identificata da una chiave unica e associata ad una descrizione (includente un puntatore al possessore della risorsa). Ogni peer riceve un ID random nello stesso spazio delle resource keys, ed è responsabile del salvataggio dei pairs di un sottoinsieme limitato dell'intero key space. Per la pubblicazione, viene associata alla descrizione di una risorsa un pair <key, value>, e la risorsa viene inviata al peer con l'ID più simile all'ID della risorsa ricorsivamente, finché l'ID più vicino non è quello attuale. Per il lookup, poi, le query vengono propagate verso il peer con l'ID più simile a quello della risorsa desiderata.

Layered Overlay Schemes Nelle architetture layered, i peer sono raggruppati in strati, ognuno dei quali ha uno schema dei suddetti. L'interazione tra strati è definita da un protollo specifico dell'applicazione. Un esempio tipico è quello a 2 layer, dove i peer con banda e potenza maggiore funzionano da **supernodi**, assumendo la responsabilità di propagare i messaggi, mentre i peer con capacità minori sono semplicemente fornitori e consumatori di risorse, e devono connettersi al supernode layer per pubblicare/trovare risorse condivise.